

UNIVERSIDADE FEDERAL DO ABC
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO
PROJETO DE GRADUAÇÃO EM COMPUTAÇÃO (PGC)

**Iridologia sob Lentes Científicas:
Avaliação Crítica com Aprendizado de Máquina**

*Da hipótese iridológica aos biomarcadores médicos da íris:
vascularização, diâmetro pupilar e morfologia para inferência de DM2*

Resumo

Este Projeto de Graduação em Computação (PGC) investiga se fotografias convencionais da íris permitem estimar alterações oculares associadas ao diabetes mellitus tipo 2 (DM2) com técnicas de visão computacional e aprendizado de máquina. O trabalho não utiliza mapas da iridologia, prática sem respaldo clínico. A análise se concentra em grandezas estudadas na literatura médica: vascularização da íris, diâmetro pupilar e morfologia iridiana e pupilar. Estudos com AS-OCTA relatam redução da densidade vascular da íris em pessoas com DM2 (Zhou et al., 2025) e mostram que essa modalidade permite visualizar a vascularização iridiana (Roberts et al., 2017; Zett et al., 2018). Outros trabalhos descrevem alterações no diâmetro pupilar e na espessura da íris (Cui et al., 2024; Thakar et al., 2025).

Foi reimplementado um fluxo computacional que inclui segmentação de íris e pupila, normalização geométrica *rubber sheet*, extração de descritores de intensidade, *Local Binary Patterns* e Haralick e validação cruzada estratificada por grupos. A avaliação por pessoa depende de identificadores reais. Como a base legada não contém esses identificadores e não permite confirmar que a classe positiva corresponde especificamente a DM2, seus resultados são apresentados somente como uma análise provisória dos rótulos fornecidos.

O projeto também define o conjunto de metadados necessário para uma avaliação clínica, incorpora ResNet, EfficientNet e *Vision Transformers*, acrescenta descritores morfológicos e cromáticos e mede correlatos de vascularização em imagens RGB. Esses correlatos não substituem medidas obtidas por AS-OCTA. O objetivo desta etapa é verificar a viabilidade e a estabilidade das medidas, controlar fontes de viés e registrar as condições necessárias para uma avaliação posterior com dados clínicos verificáveis.

Palavras-chave: diabetes mellitus tipo 2; íris; vascularização; diâmetro pupilar; visão computacional; aprendizado de máquina; aprendizado profundo; biomarcadores oculares.

Índice

1	Introdução	1
2	Problema e Questões de Pesquisa	2
2.1	Contexto e motivação	2
2.2	Problema central	2
2.3	Questões específicas	2
3	Objetivos	3
3.1	Objetivo geral	3
3.2	Objetivos específicos	3
4	Fundamentação Teórica	4

4.1	Anatomia do segmento anterior e a íris	4
4.2	Morfologia da íris e a coroa pupilar	5
4.3	Diabetes mellitus tipo 2 e o olho	6
4.4	Vascularização da íris no DM2	6
4.5	Diâmetro pupilar, espessura iridiana e disautonomia	7
4.6	Descritores cromáticos	7
4.7	Visão computacional e aprendizado profundo	7
5	Trabalhos Relacionados	8
6	Metodologia Proposta	9
6.1	Fluxo computacional de base	9
6.2	Estudo de viabilidade: medidas oculares a partir de imagens RGB	9
6.3	Eixo 1 — Base de trabalho e proveniência clínica	10
6.4	Eixo 2 — Arquiteturas profundas	11
6.5	Eixo 3 — Caracterização morfológica da íris e da coroa pupilar	11
6.6	Eixo 4 — Descritores cromáticos	12
6.7	Particionamento, métricas e robustez	12
6.8	Aspectos éticos e de tratamento de dados	13
7	Cronograma	13
8	Resultados Esperados e Contribuições	14

1 Introdução

A textura da íris permite distinguir indivíduos e é utilizada em sistemas biométricos (Daugman, 2004). A íris também contém vasos e os músculos responsáveis pelo controle do diâmetro pupilar. Essas características aparecem tanto em estudos médicos sobre manifestações oculares de doenças sistêmicas quanto em práticas sem respaldo científico, como a *iridologia*.

A iridologia sustenta que regiões da íris se mapeariam topograficamente a órgãos e sistemas, de modo que alterações locais refletiriam disfunções internas. Quando avaliada sob protocolos controlados, no entanto, a prática apresenta baixa acurácia e confiabilidade diagnóstica (Ernst, 2000; Simon et al., 1979). Em uma etapa preliminar deste projeto, utilizou-se código legado para testar se imagens da íris conteriam *signal estatístico* associado ao diabetes. A auditoria posterior do material identificou 73 linhas duplicadas entre 196 amostras e ausência de identificadores reais de indivíduo. Assim, o resultado histórico de acurácia próxima de 0,92 não constitui evidência de particionamento por pessoa nem de associação específica com DM2. Essa constatação motivou a reimplementação do código, com deduplicação, registro dos *folds*, múltiplas métricas e bloqueios explícitos quando identidade e diagnóstico não podem ser verificados.

Por essa razão, este PGC não procura confirmar mapas iridológicos. O objeto de estudo são medidas oculares presentes na literatura clínica sobre DM2: vascularização da íris, diâmetro pupilar, espessura e morfologia iridianas. A distinção é importante porque essas medidas podem ser definidas e comparadas, enquanto as associações topográficas propostas pela iridologia não encontram suporte em avaliações controladas.

Estudos com angiografia por tomografia de coerência óptica do segmento anterior (AS-OCTA) relatam redução da densidade vascular da íris em pessoas com DM2, inclusive sem retinopatia diabética (Zhou et al., 2025), e avaliam a identificação da vasculatura iridiana (Roberts et al., 2017; Zett et al., 2018). Também há relatos de alterações no diâmetro pupilar e na espessura da íris (Cui et al., 2024; Thakar et al., 2025). A partir desses resultados, o projeto pergunta se fotografias convencionais contêm correlatos mensuráveis dessas grandezas, ainda que sem a informação vascular fornecida pela AS-OCTA.

O estudo é exploratório. Ele examina a viabilidade técnica dessas medidas, sua sensibilidade às condições de aquisição e o desempenho dos classificadores sob um protocolo reproduzível. O arquivo legado serve apenas para validar a execução e produzir uma análise provisória. Conclusões sobre DM2 e generalização por pessoa dependem de rótulos clínicos verificáveis, identificadores reais e validação em um conjunto independente.

2 Problema e Questões de Pesquisa

2.1 Contexto e motivação

A literatura clínica clássica não sustenta a iridologia como método diagnóstico (Ernst, 2000; Simon et al., 1979). Por outro lado, a medicina reconhece que o olho — incluindo o segmento anterior — pode manifestar repercussões sistêmicas do DM2. A microangiopatia diabética, por exemplo, não se restringe à retina: estudos com AS-OCTA evidenciam rarefação vascular na íris (Zhou et al., 2025), enquanto disautonomia diabética afeta a dinâmica pupilar (Thakar et al., 2025). Surge, então, uma oportunidade de pesquisa distinta da iridologia: investigar se **grandezas oculares clinicamente reconhecidas** associadas ao DM2 podem ser *aproximadas* a partir de imagens convencionais por visão computacional, e se tais aproximações carregam sinal útil.

A avaliação deve verificar se o desempenho observado é reprodutível, permanece estável entre reamostragens, não decorre de artefatos de aquisição ou vazamento de dados e admite interpretação compatível com as medidas oculares investigadas. O particionamento por pessoa só pode ser avaliado quando houver identificadores reais.

2.2 Problema central

É viável aproximar, a partir de fotografias convencionais da íris e por meio de visão computacional e aprendizado de máquina, biomarcadores oculares clinicamente associados ao DM2 — vascularização, diâmetro pupilar e morfologia iridiana — de modo reprodutível, generalizável e controlado contra viés?

2.3 Questões específicas

1. **Viabilidade de extração de medidas oculares.** É possível extrair, de imagens RGB, correlatos confiáveis de (a) vascularização/textura vascular, (b) diâmetro pupilar e geometria da coroa pupilar, e (c) morfologia iridiana (criptas, sulcos, colarete), apesar das limitações de fotografias não obtidas por AS-OCTA?
2. **Validade e estabilidade do sinal.** Em um conjunto com diagnóstico de DM2 e identificadores reais, o desempenho preditivo permanece consistente entre *folds*, sementes e perturbações fotométricas quando o particionamento é feito por pessoa?

3. **Contribuição das arquiteturas profundas.** Arquiteturas como ResNet, EfficientNet e *Vision Transformers*, sob *transfer learning* e particionamento por pessoa, agregam capacidade discriminativa real em relação à linha de base clássica, ou apenas ampliam o risco de sobreajuste e de captura de artefatos?
4. **Interpretabilidade morfológica e cromática.** Descritores morfológicos (desvios em relação à circunferência ajustada, estruturas locais) e cromáticos (HSV e LAB) fornecem ganho consistente e clinicamente plausível, ou se comportam como ruído sob múltiplas comparações?

3 Objetivos

3.1 Objetivo geral

Investigar se fotografias convencionais da íris permitem estimar correlatos de vascularização, diâmetro pupilar e morfologia iridiana e pupilar associados ao DM2, utilizando visão computacional e aprendizado de máquina. A avaliação deve controlar fontes de viés e vazamento de dados e medir a capacidade de generalização.

3.2 Objetivos específicos

- **Revisão médica e computacional.** Sintetizar a evidência clínica sobre alterações oculares do segmento anterior no DM2 (vascularização, diâmetro pupilar, espessura/morfologia) e os métodos de visão computacional aplicáveis à extração dessas grandezas a partir de imagens RGB.
- **Estudo de viabilidade das medidas oculares.** Implementar e avaliar técnicas de visão computacional para estimar correlatos de vascularização (realce e densidade de estruturas vasculares/texturais), diâmetro pupilar e geometria da coroa pupilar, documentando limites e incertezas dessas estimativas em imagens convencionais.
- **Eixo 1 — Base de trabalho e proveniência clínica.** Consolidar uma base com rótulo clínico de DM2 verificável, identificador real de indivíduo, lateralidade e fonte do diagnóstico. Enquanto esses metadados não estiverem disponíveis, restringir o arquivo legado à validação operacional e à análise exploratória de rótulos reportados, sem alegar particionamento por pessoa.

- **Eixo 2 — Arquiteturas profundas.** Incorporar ResNet, EfficientNet e *Vision Transformers* sob *transfer learning* e, após a obtenção dos identificadores reais, particionamento por pessoa, comparando-as com a linha de base clássica sob as mesmas divisões.
- **Eixo 3 — Caracterização morfológica.** Quantificar a morfologia da íris e da coroa pupilar por meio de desvios em relação à circunferência ajustada e da identificação de estruturas (criptas, sulcos, colaretes), conectando-as ao diâmetro pupilar.
- **Eixo 4 — Descritores cromáticos.** Introduzir descritores baseados em momentos de cor e histogramas regionais nos espaços HSV e LAB, avaliando seu ganho marginal sobre os descritores existentes.
- **Integração e avaliação crítica.** Integrar as extensões ao fluxo computacional, permitindo comparações diretas com múltiplas métricas (acurácia, sensibilidade, especificidade, precisão e F1) e análises de estabilidade (reamostragens, *folds* e sementes).

4 Fundamentação Teórica

4.1 Anatomia do segmento anterior e a íris

A íris é o diafragma colorido do olho, situado no segmento anterior, entre a córnea e o cristalino (Figura 1). Ela separa as câmaras anterior e posterior e controla a quantidade de luz que atinge a retina por meio da pupila, cujo diâmetro é regulado por dois músculos antagonistas: o esfíncter da pupila (constrição/miose) e o dilatador (dilatação/midríase). A íris é vascularizada pelo *círculo arterial maior* e por ramos radiais que convergem em direção à pupila, e sua superfície anterior exibe estruturas características — criptas, sulcos de contração e o *colarete* (ou coroa) — relevantes tanto para biometria (Daugman, 2004) quanto para a caracterização morfológica proposta neste projeto.




Figura 1: Corte esquemático do olho humano. Estruturas de interesse direto para este projeto situam-se no segmento anterior: **6 – íris**, **4 – pupila**, **2 – câmara anterior** e **3 – córnea**. Diagrama de Rhcastilhos, editado por User:Jakov, em domínio público via Wikimedia Commons.

4.2 Morfologia da íris e a coroa pupilar

A Figura 2 apresenta uma macrofotografia da íris na qual se observam o padrão radial de fibras (trabéculas), criptas e o colarete — a faixa sinuosa que delimita a zona pupilar (interna) da zona ciliar (externa). Essas estruturas constituem o substrato visual da **caracterização morfológica** (Eixo 3): desvios da borda pupilar em relação a uma circunferência ajustada, ondulações do colarete e densidade de criptas são candidatos a descritores quantitativos. Do ponto de vista médico, a geometria da coroa pupilar e a regularidade da borda pupilar relacionam-se ao tônus muscular e, indiretamente, à integridade da inervação autonômica, frequentemente comprometida no DM2 (Thakar et al., 2025).




Figura 2: Macrofotografia ilustrativa da íris evidenciando o padrão radial de fibras, criptas e o colarete (faixa sinuosa que separa a zona pupilar da zona ciliar). Estas estruturas são alvo da caracterização morfológica proposta no Eixo 3. Crédito: Carlos Andrés Reyes, via Wikimedia Commons, licença CC BY 2.0 (imagem com pós-processamento artístico; uso meramente ilustrativo).

4.3 Diabetes mellitus tipo 2 e o olho

O DM2 é uma doença metabólica crônica de alta prevalência, associada a complicações micro e macrovasculares ([WHO, 2024](#)). A complicação ocular mais estudada é a retinopatia diabética, mas a microangiopatia e a neuropatia autonômica também afetam o **segmento anterior**. Esses efeitos mensuráveis na íris e na pupila fornecem a referência clínica utilizada neste trabalho, sem recorrer a pressupostos iridológicos.

4.4 Vascularização da íris no DM2

Evidências com AS-OCTA indicam que a densidade vascular da íris é **reduzida** em pacientes com DM2, inclusive na ausência de retinopatia diabética. [Zhou et al. \(2025\)](#) avaliaram a vasculatura iridiana em pacientes com DM2 sem retinopatia e observaram redução significativa da densidade vascular da íris (íris total e setores nasal e temporal), com associações a sexo, índice de massa corporal e glicemia. Trabalhos metodológicos demonstram a viabilidade de identificar e estadiar a vasculatura da íris

por AS-OCTA (Roberts et al., 2017) e de compará-la à angiofluoresceinografia (Zett et al., 2018). Embora a AS-OCTA não esteja disponível em fotografias convencionais, esses estudos motivam a investigação de correlatos texturais e cromáticos da vascularização em imagens RGB. Métodos de aprendizado de máquina também foram aplicados à análise quantitativa de angiografias da íris (Zhu et al., 2026).

4.5 Diâmetro pupilar, espessura iridiana e disautonomia

Cui et al. (2024) estudaram a relação entre fluxo sanguíneo da íris, espessura iridiana e diâmetro pupilar em repouso e após midríase farmacológica em diabéticos, encontrando, em adultos com DM2, íris mais delgada na região do dilatador e **menor diâmetro pupilar** — com a hemoglobina glicada (HbA1c) atuando como fator independente do diâmetro pupilar após dilatação. De modo convergente, Thakar et al. (2025) reportam, por pupilometria automatizada, **diâmetros pupilares significativamente menores** em diabéticos, com correlação a parâmetros de neurodegeneração retiniana. Esses achados sustentam o **diâmetro pupilar e a dinâmica pupilar** como biomarcadores candidatos, potencialmente estimáveis por visão computacional a partir da segmentação pupila/íris.

4.6 Descritores cromáticos

O projeto quantifica a cor da íris com momentos de cor (média, desvio-padrão e assimetria) e histogramas regionais nos espaços HSV e LAB. Esses espaços separam componentes de luminância e cromaticidade e permitem testar se os descritores permanecem estáveis sob mudanças de iluminação e contraste.

4.7 Visão computacional e aprendizado profundo

A normalização *rubber sheet* (Daugman, 2004) mapeia a região anelar da íris para coordenadas polares (raio $\times$ ângulo), facilitando a extração de descritores comparáveis entre amostras. Sobre essa representação aplicam-se descritores clássicos — intensidades de pixel, *Local Binary Patterns* (Ojala et al., 2002) e descritores de Haralick derivados da matriz de coocorrência (Haralick et al., 1973). Também são avaliadas arquiteturas de aprendizado profundo — ResNet (He et al., 2016), EfficientNet (Tan e Le, 2019) e *Vision Transformers* (Dosovitskiy et al., 2021) —, ajustadas por *transfer learning* (Pan e Yang, 2010). A aplicação dessas técnicas à oftalmologia inclui a detecção de retinopatia diabética em retinografias (Gulshan et al., 2016). Modelos

com maior capacidade também podem aprender atalhos relacionados à aquisição (Zech et al., 2018); por isso, a avaliação por pessoa depende de identificadores reais.

5 Trabalhos Relacionados

A Tabela 1 reúne estudos sobre íris, segmento anterior e DM2. Os trabalhos clínicos medem vascularização, diâmetro pupilar e espessura com equipamentos próprios para essas grandezas. Eles servem como referência para avaliar quais correlatos podem ser obtidos de fotografias convencionais e quais informações dependem de modalidades como AS-OCTA.

Tabela 1: Trabalhos relacionados: biomarcadores médicos da íris/pupila no DM2 e métodos associados.

Referência	Ano	Foco / biomarcador	Método
Zhou et al.	2025	Densidade vascular da íris reduzida em DM2 sem retinopatia	AS-OCTA; análise estatística por setores
Cui et al.	2024	Fluxo sanguíneo, espessura da íris e diâmetro pupilar (repouso e pós-midríase)	OCTA + AS-OCT + pupilômetro
Thakar et al.	2025	Diâmetro pupilar menor em diabéticos; correlação com camada de fibras nervosas	Pupilometria automatizada
Roberts et al.	2017	Identificação e estadiamento da vasculatura/neovascularização da íris	AS-OCTA (estudo piloto)
Zett et al.	2018	Vasculatura da íris: comparação de modalidades	AS-OCTA <i>vs.</i> angiofluoresceinografia
Zhu et al.	2026	Análise quantitativa de angiografia da íris	Aprendizado de máquina
Surya et al.	2026	Predição de retinopatia diabética a partir de anormalidades pupilares	ML (rede neural artificial)
Samant e Agarwal	2018	<i>Pipeline</i> de classificação de DM2 por imagens da íris (linha de base de referência)	ROI + descritores + RF

Posicionamento deste PGC. O projeto utiliza as medidas descritas na literatura clínica como referência, mas trabalha com fotografias RGB, e não com AS-OCTA. A

análise inclui deduplicação, múltiplas métricas, testes de robustez e particionamento por pessoa quando houver identificadores reais. A equivalência clínica das medidas indiretas não é presumida, e a validação externa permanece necessária.

6 Metodologia Proposta

6.1 Fluxo computacional de base

O fluxo implementado é composto por: (1) segmentação de íris e pupila; (2) normalização geométrica *rubber sheet*; (3) extração de descritores (intensidades de pixel, LBP e Haralick); (4) classificação (Regressão Logística, SVM, *Random Forest*, MLP e AdaBoost); e (5) avaliação padronizada sob validação cruzada estratificada por grupos. O particionamento só é considerado por pessoa quando os grupos correspondem a identificadores reais. Os arquivos de saída registram as divisões, os parâmetros e as versões dos pacotes utilizados, permitindo comparar cada extensão com a linha de base.

6.2 Estudo de viabilidade: medidas oculares a partir de imagens RGB

Antes das extensões de modelagem, conduz-se um estudo de viabilidade para estimar correlatos dos biomarcadores médicos (Figura 3):

- **Diâmetro pupilar e coroa pupilar.** A partir da segmentação pupila/íris, estima-se o raio/diâmetro pupilar relativo (normalizado pelo diâmetro da íris, para mitigar variações de escala/câmera) e a **razão pupila/íris**. A borda pupilar é ajustada a uma circunferência e quantificam-se os desvios radiais (Eixo 3).
- **Correlatos de vascularização.** Investigam-se realces de estruturas finas (filtros do tipo Frangi/*vesselness*, realce de cor nos canais vermelho e verde e descritores de textura) como medidas indiretas de densidade vascular. Fotografias RGB não substituem AS-OCTA; a análise mede a viabilidade e a estabilidade desses correlatos, sem afirmar equivalência clínica.
- **Morfologia iridiana.** Densidade de criptas, sulcos e ondulação do colarete são estimadas sobre a íris normalizada.

As segmentações são submetidas a controle de qualidade antes da normalização: a borda pupilar deve estar contida na borda iridiana, a largura anular deve permanecer

positiva em todo o domínio angular, as fronteiras devem permanecer dentro da imagem e o escore mínimo de qualidade deve ser atendido. Falhas são registradas e excluídas, sem substituição silenciosa de medidas.




Figura 3: Visão geral do fluxo proposto. O processamento de base (azul) alimenta quatro grupos de descritores (verde), incluindo medidas oculares indiretas, e a avaliação dos classificadores (laranja).

6.3 Eixo 1 — Base de trabalho e proveniência clínica

O arquivo legado recebido contém 108 linhas reportadas como controle e 88 como diabetes, mas não inclui identificadores reais, lateralidade, fonte do diagnóstico ou confirmação do subtipo DM2. A auditoria removeu 73 cópias exatas, restando 123 imagens únicas (66 controles reportados e 57 casos reportados como diabetes). Portanto, essa base não dispensa a recuperação de metadados nem permite afirmar isolamento por pessoa. O protocolo definitivo exige um manifesto com identificador real, lateralidade, rótulo binário e fonte do diagnóstico; todas as imagens do mesmo indivíduo são mantidas no mesmo grupo.

Enquanto o manifesto clínico não estiver disponível, o arquivo legado é usado somente em uma análise provisória, mediante autorização explícita na linha de comando. A Figura 4 resume a acurácia dos cinco classificadores sobre o conjunto completo de descritores, em três sementes e cinco *folds* por semente. O melhor resultado nessa configuração foi do *Random Forest* (acurácia média 0,829), enquanto a melhor ablação foi AdaBoost com descritores clássicos (0,840). Esses valores demonstram a execução do protocolo; não demonstram associação específica com DM2 nem generalização entre pessoas reais. A validação em conjunto independente permanece necessária. A publicação associada ao arquivo também foi retratada pelo IEEE (IEEE, 2023); por isso,

o conjunto não é usado como evidência científica, e qualquer uso futuro depende de esclarecimento com o custodiante dos dados sobre proveniência, licença, consentimento e implicações da retratação.




Figura 4: Linha de base provisória sobre 123 imagens únicas do arquivo legado: acurácia média de cinco classificadores com todos os descritores, em três sementes e cinco *folds* por semente. Os grupos são IDs sintéticos por linha, não identificadores reais de pessoa, e a classe positiva significa diabetes reportado, sem confirmação do subtipo DM2.

6.4 Eixo 2 — Arquiteturas profundas

Avaliam-se ResNet, EfficientNet e *Vision Transformers* sob *transfer learning* (pesos pré-treinados em ImageNet), com ajuste fino das camadas superiores. O particionamento por pessoa será aplicado quando houver identificadores reais. A comparação com a linha de base clássica verifica se essas arquiteturas acrescentam informação ou apenas aumentam o sobreajuste.

6.5 Eixo 3 — Caracterização morfológica da íris e da coroa pupilar

A morfologia é quantificada por **desvios em relação à circunferência ajustada** (Figura 5). Ajusta-se uma circunferência à borda pupilar (e à fronteira entre íris e esclera) e mede-se, em cada ângulo θ , o desvio radial $\delta(\theta) = r_{\text{borda}}(\theta) - r_{\text{circ}}(\theta)$.

Estatísticas de $\delta(\theta)$ (amplitude, energia espectral, número de lóbulos) descrevem a regularidade da coroa pupilar e da borda pupilar, relacionando-se ao tônus muscular e à inervação autonômica.




Figura 5: Esquema da caracterização morfológica (Eixo 3). A borda pupilar real (vermelho) é comparada a uma circunferência ajustada (tracejada); o desvio radial $\delta(\theta) = r_{\text{borda}}(\theta) - r_{\text{circ}}(\theta)$ e a geometria do colarete (pontilhado) descrevem a regularidade da coroa pupilar.

6.6 Eixo 4 — Descritores cromáticos

Sobre a íris normalizada, extraem-se **momentos de cor** (média, desvio-padrão e assimetria por canal) e **histogramas regionais** nos espaços **HSV** e **LAB**, globalmente e por setores. Avalia-se o ganho marginal desses descritores sobre os descritores clássicos, bem como sua estabilidade sob transformações fotométricas (contraste/iluminação).

6.7 Particionamento, métricas e robustez

Mantêm-se os controles metodológicos de base: (i) particionamento por pessoa como salvaguarda contra vazamento por identidade, condicionado a identificadores reais; (ii) validação cruzada estratificada por grupos; (iii) métricas múltiplas — acurácia, sensibilidade, especificidade, precisão e F1 —, com média e desvio-padrão entre *folds*; e (iv) testes de robustez (sementes, reamostragens e perturbações fotométricas). Para as análises locais e de múltiplos descritores, adota-se cautela quanto a **múltiplas comparações**, tratando achados locais como hipóteses candidatas a confirmação.

6.8 Aspectos éticos e de tratamento de dados

Por envolver imagens associadas a uma condição de saúde (DM2), o trabalho observa princípios de integridade em pesquisa e de proteção de dados. Antes de qualquer divulgação, a proveniência, a licença de uso, a anonimização e a base legal do conjunto devem ser documentadas. O arquivo legado atual não contém informação suficiente para comprovar esses requisitos e, por isso, permanece restrito à validação operacional local. Não se realizam procedimentos clínicos nem se emitem diagnósticos individuais: os modelos são avaliados exclusivamente em nível de pesquisa, com finalidade exploratória. Caso etapas futuras demandem a aquisição de novas imagens em ambiente clínico, prevê-se a submissão a Comitê de Ética em Pesquisa (CEP) e a obtenção de consentimento livre e esclarecido, em conformidade com a Resolução CNS nº 466/2012 e com a Lei Geral de Proteção de Dados (LGPD, Lei nº 13.709/2018). Ressalta-se, ademais, que a iridologia não constitui método diagnóstico reconhecido pela medicina, de modo que os resultados deste trabalho não devem ser interpretados como validação de práticas iridológicas.

7 Cronograma

O projeto distribui-se entre PGC I (planejamento, fundamentação e viabilidade) e PGC II (extensões, integração e redação final), conforme a Tabela 2.

Tabela 2: Cronograma previsto de atividades (PGC I e PGC II). Cada bloco • indica um mês de atividade prevista.

Atividade	PGC I						PGC II					
	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12
Revisão médica e computacional	•	•	•									
Estudo de viabilidade (medidas oculares)		•	•	•								
Consolidação do fluxo computacional			•	•	•							
Eixo 3 — Caracterização morfológica				•	•	•						
Eixo 4 — Descritores cromáticos					•	•	•					
Relatório/Defesa de PGC I						•						
Eixo 2 — Arquiteturas profundas							•	•	•			
Eixo 1 — Base de trabalho rotulada para DM2								•	•	•		
Análises de robustez e integração final									•	•	•	
Redação, revisão e defesa de PGC II										•	•	•

8 Resultados Esperados e Contribuições

O projeto tem caráter exploratório e prevê os seguintes resultados:

- um **diagnóstico de viabilidade** sobre extrair correlatos de vascularização, diâmetro pupilar e morfologia iridiana de imagens RGB convencionais, com limites e incertezas explicitados;
- uma **reavaliação da base legada**, limitada aos rótulos reportados, com as medidas oculares, os novos descritores e os testes de robustez, seguida por uma avaliação clínica quando houver confirmação de DM2 e identificadores reais;
- uma **comparação** entre descritores clássicos, morfológicos, cromáticos e arquiteturas profundas, sob os mesmos *folds* e, quando possível, particionamento por pessoa;
- um fluxo computacional que registra dados, parâmetros, divisões e resultados e que pode ser reaplicado quando uma base clinicamente verificável estiver disponível.

A principal contribuição é metodológica. O trabalho define como testar, sem pressupostos iridológicos, se fotografias da íris contêm medidas associadas ao DM2. O protocolo explicita as limitações da base legada, controla vazamento de dados e estabelece os dados necessários para uma validação clínica posterior.

Referências

- Cui, L.; Xiao, Y.; Xiang, Z.; Chen, Z.; Yang, C.; Zou, H. Study on the correlation between iris blood flow, iris thickness and pupil diameter in the resting state and after pharmacological mydriasis in patients with diabetes mellitus. *BMC Ophthalmology*, 24(1):52, 2024. doi: 10.1186/s12886-024-03322-y.
- Daugman, J. How iris recognition works. *IEEE Transactions on Circuits and Systems for Video Technology*, 14(1):21–30, 2004. doi: 10.1109/TCSVT.2003.818350.
- Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; Uszkoreit, J.; Houlsby, N. An image is worth 16×16 words: Transformers for image recognition at scale. In: *International Conference on Learning Representations (ICLR)*, 2021.
- Ernst, E. Iridology: a systematic review. *Archives of Ophthalmology*, 118(1):120–121, 2000.
- Gulshan, V.; Peng, L.; Coram, M.; et al. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA*, 316(22):2402–2410, 2016. doi: 10.1001/jama.2016.17216.
- Haralick, R. M.; Shanmugam, K.; Dinstein, I. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, 3(6):610–621, 1973. doi: 10.1109/TSMC.1973.4309314.
- He, K.; Zhang, X.; Ren, S.; Sun, J. Deep residual learning for image recognition. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 770–778, 2016. doi: 10.1109/CVPR.2016.90.
- Ojala, T.; Pietikäinen, M.; Mäenpää, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987, 2002. doi: 10.1109/TPAMI.2002.1017623.
- Pan, S. J.; Yang, Q. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010. doi: 10.1109/TKDE.2009.191.
- Roberts, P. K.; Goldstein, D. A.; Fawzi, A. A. Anterior segment optical coherence tomography angiography for identification of iris vasculature and staging of iris neovascularization: a pilot study. *Current Eye Research*, 42(8):1136–1142, 2017. doi: 10.1080/02713683.2017.1293113.

- Samant, P.; Agarwal, R. Machine learning techniques for medical diagnosis of diabetes using iris images. *Computer Methods and Programs in Biomedicine*, 157:121–128, 2018. doi: 10.1016/j.cmpb.2018.01.004.
- IEEE. Retraction notice: Discovering informative regions in iris images to predict diabetes. In: *2018 25th National and 3rd International Iranian Conference on Biomedical Engineering (ICBME)*, 2023. doi: 10.1109/ICBME45317.2018.10207763.
- Simon, A.; Worthen, D. M.; Mitas, J. A. An evaluation of iridology. *JAMA*, 242(13):1385–1389, 1979.
- Surya, J.; Tamilselvi, S.; Roy, M.; et al. Machine learning-based prediction of diabetic retinopathy from pupillary abnormalities in a South Indian population. *PLoS ONE*, 21(1):e0340802, 2026. doi: 10.1371/journal.pone.0340802.
- Tan, M.; Le, Q. V. EfficientNet: Rethinking model scaling for convolutional neural networks. In: *International Conference on Machine Learning (ICML)*, p. 6105–6114, 2019.
- Thakar, M.; et al. Quantitative automated pupillometry in diabetic patients and correlation with retinal nerve fibre layer thickness. *Eye (London)*, 39(10):1983–1989, 2025. doi: 10.1038/s41433-025-03793-3.
- World Health Organization (WHO). Diabetes (Fact sheet), 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/diabetes>.
- Zech, J. R.; Badgeley, M. A.; Liu, M.; Costa, A. B.; Titano, J. J.; Oermann, E. K. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*, 15(11):e1002683, 2018. doi: 10.1371/journal.pmed.1002683.
- Zett, C.; Stina, D. M. R.; Kato, R. T.; Novais, E. A.; Allemann, N. Comparison of anterior segment optical coherence tomography angiography and fluorescein angiography for iris vasculature analysis. *Graefe's Archive for Clinical and Experimental Ophthalmology*, 256(4):683–691, 2018. doi: 10.1007/s00417-018-3935-7.
- Zhou, Y.; Wang, T.; Guo, Z.; She, F.; Zeng, J.; Zhu, X. Assessment of iris vasculature in type 2 diabetes mellitus patients without diabetic retinopathy using anterior segment optical coherence tomography angiography. *Scientific Reports*, 15(1):19035, 2025. doi: 10.1038/s41598-025-04463-w.
- Zhu, Y.; Sun, S.; Han, S.; Chen, J.; Western, D.; Zhang, L. Automated method for quantitative analysis of iris fluorescein angiography based on machine learning.

Quantitative Imaging in Medicine and Surgery, 16(1):68, 2026. doi: 10.21037/qims-2025-480.